



Estudio de técnicas de pre-filtrado en modelos de machine learning para manejar datos de alta-dimensionalidad

Cristina Ordaz, Pedro Contró, Aida Calviño y Silvia Pineda
Máster Bioestadística Universidad Complutense de Madrid

Introducción

El Machine Learning engloba un conjunto de técnicas estadísticas y computacionales capaces de extraer patrones y conocimiento útil a partir de datos complejos. En el ámbito biomédico, y especialmente en datos ómicos, es habitual enfrentarse a escenarios **HDLSS** (High Dimension, Low Sample Size) donde $p \gg n$, lo que provoca que los modelos clásicos sobreajusten y pierdan capacidad de generalización. En este contexto, los métodos de prefiltrado reducen el espacio de variables eliminando aquellas con menor relevancia, disminuyendo el ruido y mejorando el rendimiento predictivo de los modelos resultantes.

Este estudio utiliza datos transcriptómicos de expresión génica de tumores primarios de mama, obtenidos mediante RNA-seq de la cohorte SCAN-B [1] y disponibles en el repositorio público GEO. Cada muestra cuenta con los niveles de expresión de miles de genes, lo que configura un escenario de alta dimensionalidad donde $p \gg n$. La variable respuesta indica el subtipo tumoral, codificada como 1 si el tumor es de tipo Luminal A y 0 en caso contrario. En este contexto, los modelos clásicos de regresión logística dejan de ser adecuados, ya que, aunque producen estimaciones insesgadas, la varianza de dichas estimaciones se dispara cuando p es grande en relación a n . [2].

Objetivos del estudio

1. Estudiar métodos de prefiltrado de variables para simplificar matrices de alta dimensionalidad en datos biomédicos y mejorar el rendimiento de los modelos predictivos.
2. Analizar técnicas de data augmentation para aumentar el tamaño muestral y mejorar la relación variables-observaciones.
3. Evaluar la combinación de ambos enfoques para desarrollar modelos más robustos.

Material y Métodos



En este estudio, se recurre a la **regularización Lasso** (L1), que introduce una penalización sobre los coeficientes del modelo:

$$\min_{\beta} \left[-\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)] \right] + \lambda \sum_{j=1}^p |\beta_j|$$

donde $y_i \in \{0,1\}$ es la clase observada, $\hat{p}_i = P(Y = 1|x_i, \beta)$ la probabilidad predicha, y $\lambda \geq 0$ el parámetro de regularización.

Esta penalización fuerza a que algunos coeficientes sean exactamente cero, realizando simultáneamente estimación y selección de variables. Como paso previo al ajuste del modelo, se aplican distintas **estrategias de prefiltrado** con el objetivo de reducir la dimensionalidad inicial y transformar el problema en uno más manejable. En concreto, se consideran tres enfoques:

- **P-valor**, retiene las variables con mayor evidencia estadística de asociación con la variable respuesta [3].
- **MRMR** (Minimum Redundancy Maximum Relevance), que selecciona variables maximizando su relevancia respecto a la variable objetivo y minimizando al mismo tiempo la redundancia entre las variables ya seleccionadas [3].
- **CMIM** (Conditional Mutual Information Maximization), que selecciona variables maximizando la información mutua con la variable objetivo mediante un procedimiento forward, sin penalizar explícitamente la redundancia [3].



Principales resultados

Comparación de resultados iniciales




Figura 1. Procedimientos A y B

El Procedimiento B muestra un **rendimiento equiparable** al del Procedimiento A (escenario base), con una ligera penalización únicamente cuando el número de variables retenidas es inferior a 1000, umbral a partir del cual se estabiliza (Figura 1). Entre las estrategias de prefiltrado, el p-valor obtiene el rendimiento más bajo, mientras que MRMR presenta una caída puntual con 100 variables, atribuible a oscilaciones propias de la convergencia, seguida de una rápida recuperación. CMIM es el filtro con mejor rendimiento, llegando a superar al Procedimiento A con más de 500 variables retenidas.

Selección de variables en el Procedimiento B




Figura 2. Solapamiento de variables

La Figura 2 muestra el solapamiento entre las variables seleccionadas por los tres métodos de filtrado. Con las 50 primeras variables (Figura 2A), el acuerdo es prácticamente nulo, ninguna variable es compartida por los tres métodos simultáneamente. Ampliar la selección a 1000 variables (Figura 2B) apenas mejora esta situación, con solo 89 variables en común. La **escasa concordancia** sugiere que cada método captura información distinta, lo que abre la puerta a estrategias que combinen su complementariedad.

Comparación de resultados modificando el tamaño muestral




Figura 3. Procedimientos C y D

La Figura 3 evidencia el **impacto del tamaño muestral**. Con $n=100$ observaciones, ninguna configuración alcanza el rendimiento del Procedimiento A. Podemos observar, que en el caso del filtro del p-valor on $p=50$, se supera el rendimiento del modelo con todas las variables. Pese a esto, decrece al aumentar el número de variables retenidas, mientras que MRMR y CMIM muestran un comportamiento inestable sin tendencia clara de mejora. Estos resultados motivan la exploración de técnicas de aumento de datos como Bootstrap o SMOTE en fases posteriores del estudio.

Conclusión

Este trabajo compara tres métodos de prefiltrado de variables en el contexto del diagnóstico de cáncer de mama a partir de datos transcriptómicos de alta dimensionalidad. Los resultados demuestran que el prefiltrado puede alcanzar un rendimiento comparable al escenario base siempre que se retenga un número suficiente de variables, siendo CMIM el método más eficaz, capaz incluso de superar al escenario de referencia en determinadas configuraciones.

Sin embargo, el análisis del solapamiento entre métodos revela que cada filtro selecciona variables sustancialmente distintas, con una concordancia mínima incluso al ampliar la selección. Lejos de ser una limitación, esta complementariedad sugiere que combinar los tres métodos podría aprovechar la información capturada por cada uno de forma independiente, constituyendo una línea de trabajo prometedora.

Por otro lado, el tamaño muestral se revela como un factor crítico: con muestras reducidas, ninguna de las configuraciones evaluadas logra alcanzar el rendimiento del escenario base, y el prefiltrado no consigue compensar esta limitación. Esto motiva la exploración de técnicas de aumento de datos como Bootstrap o SMOTE en fases posteriores del estudio, con el objetivo de mejorar la robustez de los modelos en escenarios con escasez de observaciones.

Próximos Pasos

1. Analizar técnicas de data augmentation para aumentar el tamaño muestral y mejorar la relación variables-observaciones.
2. Evaluar la combinación de ambos enfoques para desarrollar modelos más robustos.
3. Explorar la combinación de filtros dada la diferencia de selección de variables.
4. Evaluar los rendimientos observados en otros contextos.

Bibliografía

- [1] Dalal, H., Dahlgren, M., Gladchuk, S., Brueffer, C., Gruyberger-Saal, S. K., & Saal, L. H. (2022). Clinical associations of ESR2 (estrogen receptor beta) expression across thousands of primary breast tumors. Scientific Reports, 12, 4696. <https://doi.org/10.1038/s41598-022-08210-3>
- [2] Fernández-Casal, R., Costa, J., & Oviedo, M. (2024). Métodos predictivos de aprendizaje estadístico. Servicio de Publicacións, Universidade da Coruña. https://rubenfcasal.github.io/aprendizaje_estadistico/
- [3] Méndez López, Á. J. (2024). Selección de características en entornos de dimensionalidad masiva y muestra reducida: aplicación al estudio de metilación del ADN en la enfermedad de Alzheimer [Tesis doctoral]. Universidad Autónoma de Madrid.